КЛАСИФІКАЦІЯ ЗА ДОПОМОГОЮ МЕТОДУ CART

Підготував: студент ОІ-32
Криворучко Микола

ЗМІСТ

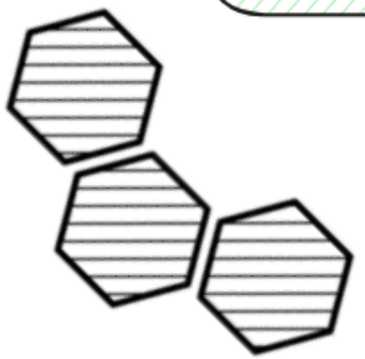

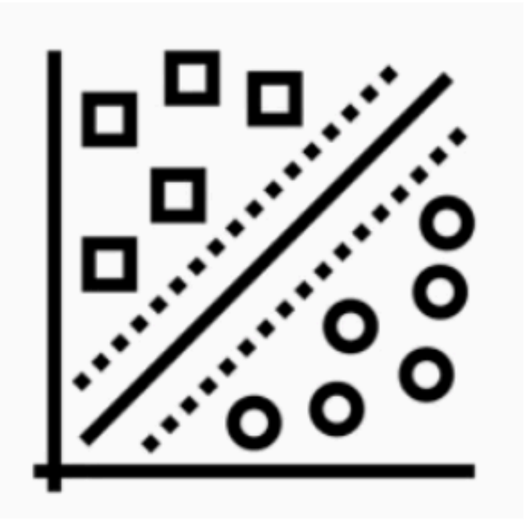

Що таке Data Mining?

Набір методів, алгоритмів та засобів опрацювання "сирих даних" із метою видобування з них необхідної інформації(знань)

Задачі Data Mining

1. Задача класифікації
2. Задача регресії
3. Задача кластеризації
4. Побудова асоціативних правил

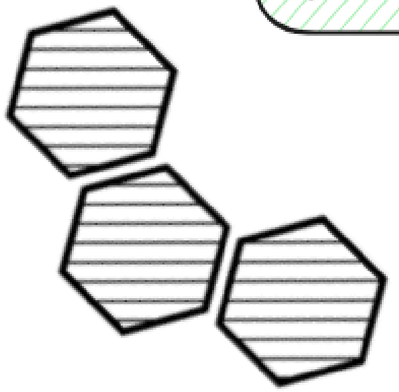

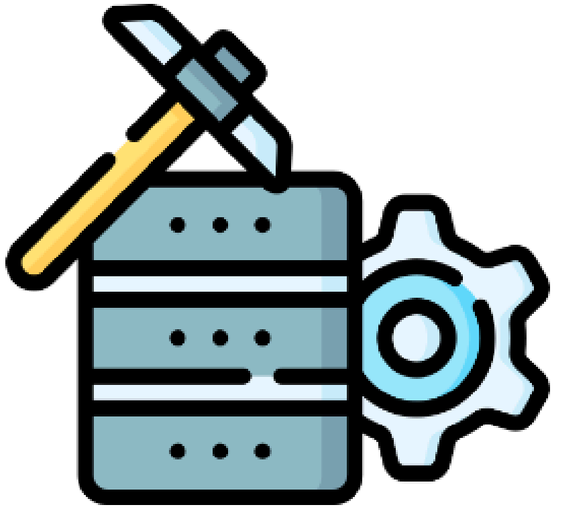

Задача класифікації

задача класифікації зводиться до визначення класу об'єкта по його характеристикам. Необхідно зауважити, що в цьому завданні множина класів, до яких може бути віднесений об'єкт, відомо заздалегідь.

Методи класифікації

- метод найближчого сусіда
- наївна байєосва класифікація
- CBR
- група присвячених побудові дерева рішень
- нейронні мережі
- генетичні алгоритми
- метод опорних векторів

CART

це алгоритм побудови бінарного дерева рішень, який може використовуватися:
- для класифікації (розбиття даних на категорії);
- для регресії (прогнозування числових значень).

Основні принципи роботи

Бінарна структура: Кожен вузол дерева ділить вибірку на дві частини (ліву й праву гілку). Тому дерево CART завжди є бінарним (тобто кожен вузол має максимум двох нащадків).

Логіка розбиття: На кожному кроці алгоритм вибирає одну ознаку і один поріг, який найкраще ділить дані.

Мета — зробити підмножини максимально «чистими», тобто щоб приклади одного класу потрапляли в одну гілку.

Індекс Gini

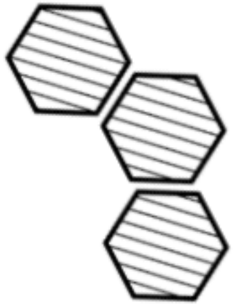

Індекс Gini у CART

- **Gini вузла:** $Gini(t) = 1 - \sum_{i=1}^{C} p_i^2$
  - p_i — частка прикладів класу i у вузлі t
  - 0 → вузол чистий (усі приклади одного класу)
  - max → приклади рівномірно змішані
- **Gini розбиття:**

$$Gini_{split} = \frac{N_1}{N} Gini(T_1) + \frac{N_2}{N} Gini(T_2)$$

- N_1, N_2 — кількість прикладів у підвузлах
- Мінімізуємо $Gini_{split}$ → найчистіше розбиття

Типи ознак

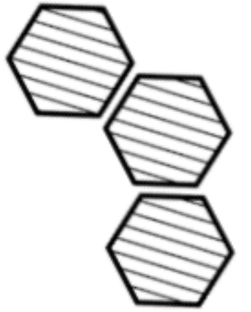

- **Числові атрибути:**

  Правило виду: $x_i \leq c$,

  де c — порогове значення (зазвичай середнє між двома сусідніми значеннями в даних).
- **Категоріальні атрибути:**

  Правило виду: $x_i \in V(x_i)$,

  де $V(x_i)$ — підмножина можливих категорій.

Відсікання дерева

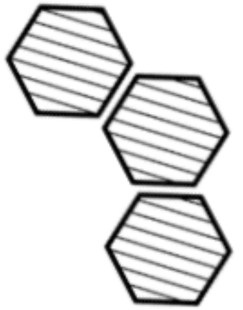

CART використовує метод Minimal Cost-Complexity Pruning

- Спочатку **вирощуємо повне дерево**, поки можливо.
- Потім поступово **відсікаємо (скорочуємо) гілки**, які мало покращують якість класифікації, щоб уникнути перенавчання.

Ідея: знайти баланс між **точністю** і **простотою** дерева.

V-fold Cross-Validation

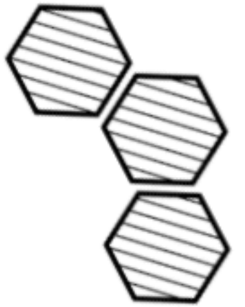

Перехресна перевірка (V-fold Cross-Validation) використовується для вибору **оптимального розміру дерева**

- Дані діляться на V частин.
- Кожного разу дерево тренується на V-1 частинах і перевіряється на решті.
- Це дозволяє стабільно оцінити якість дерева, навіть при невеликому об’ємі даних.

CART

Чи заб'є Роналду гол в матчі?

	Сила суперника	Місце матчу	Форма Роналдо	Підтримка команди	Забив
0	Сильний	В гостях	Добра	Висока	Ні
1	Слабкий	Дома	Добра	Висока	Так
2	Слабкий	В гостях	Погана	Низька	Ні
3	Слабкий	Дома	Добра	Низька	Так
4	Сильний	Дома	Добра	Висока	Так
5	Слабкий	В гостях	Погана	Низька	Ні
6	Слабкий	В гостях	Добра	Висока	Так
7	Слабкий	Дома	Погана	Низька	Ні
8	Сильний	Дома	Добра	Низька	Так
9	Слабкий	В гостях	Погана	Висока	Ні
10	Слабкий	Дома	Добра	Висока	Так
11	Сильний	В гостях	Погана	Низька	Ні

CART

Сила суперника

Забив / Сила суперника	Так	Ні	Всього
Слабкий	4	4	8
Сильний	2	2	4

Gini(сила суперника=слабкий) = 1 - (4/8)^2 - (4/8)^2 = 0.5
Gini(сила суперника=сильний) = 1 - (2/4)^2 - (2/4)^2 = 0.5

Gini(сила суперника) = 8/12 * 0.5 + 4/12 * 0.5 = 0.5

CART

Місце матчу

Забив / Місце матчу	Так	Ні	Всього
В гостях	5	1	6
Дома	1	5	6

Gini(місце матчу=в гостях) = 1 - (5/6)^2 - (1/6)^2 = 0.2778
Gini(місце матчу=дома) = 1 - (1/6)^2 - (5/6)^2 = 0.2778

Gini(місце матчу) = 8/12 * 0.2778+ 4/12 * 0.2778 = 0.2778

CART

Форма Роналду

Форма \ Забив	Так	Ні	Всього
Добра	6	1	7
Погана	0	5	5

Gini(форма Роналду=добра) = 1 - (1/7)^2 - (6/7)^2 = 0.2449
Gini(форма Роналду=погана) = 1 - (5/5)^2 - (0/5)^2 = 0

Gini(форма Роналду) = 7/12 * 0.2449+ 5/12 * 0 = 0.1429

CART

Підтримка команди

Забив / Підтримка	Так	Ні	Всього
Висока	4	2	6
Низька	2	4	6

Gini(місце матчу=в гостях) = 1 - (2/6)^2 - (4/6)^2 = 0.444
Gini(місце матчу=дома) = 1 - (4/6)^2 - (2/6)^2 = 0.444

Gini(місце матчу) = 6/12 * 0.444 + 6/12 * 0.444 = 0.444

CART

Ознака	Індекс Gini
Місце матчу	0.2778
Форма Роналду	0.1429
Підтримка команди	0.444
Сила суперника	0.5

CART

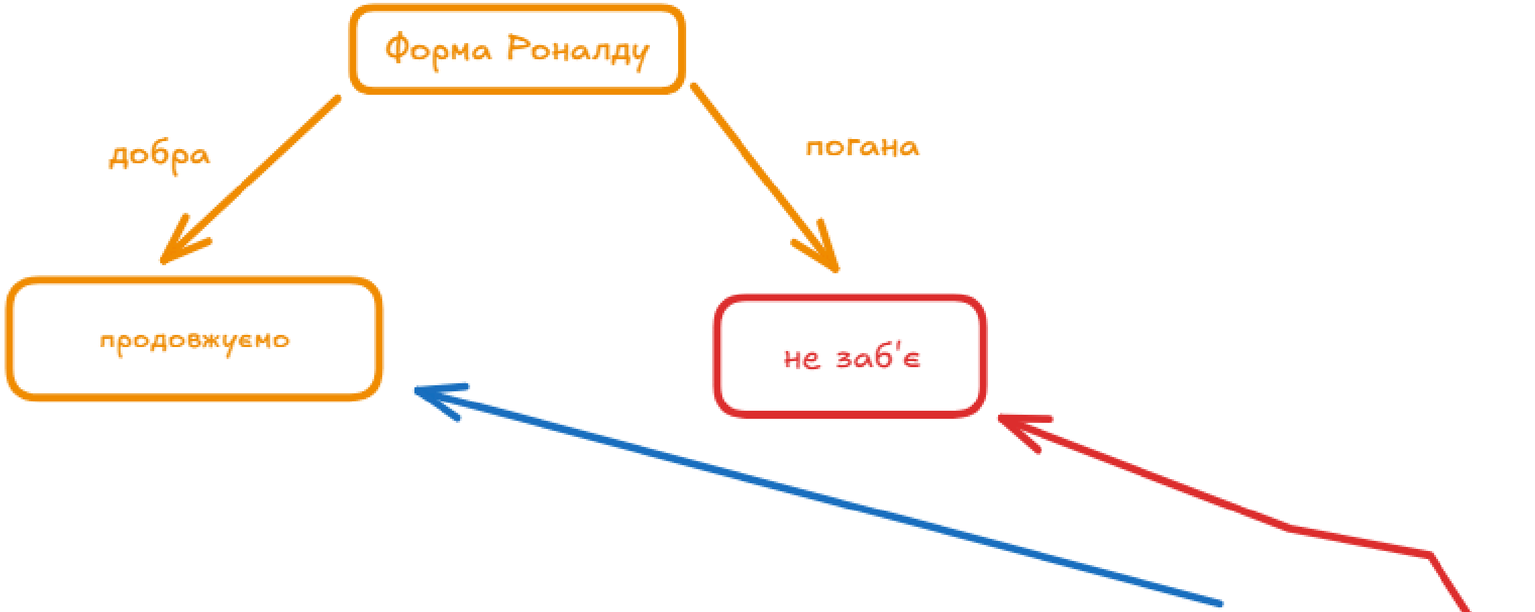

Gini(форма Роналду=добра) = 1 - (1/7)^2 - (6/7)^2 = 0.2449
Gini(форма Роналду=погана) = 1 - (5/5)^2 - (0/5)^2 = 0

Gini(форма Роналду) = 7/12 * 0.2449+ 5/12 * 0 = 0.1429

	Сила суперника	Місце матчу	Форма Роналдо	Підтримка команди	Забив
0	Сильний	В гостях	Добра	Висока	Ні
1	Слабкий	Дома	Добра	Висока	Так
3	Слабкий	Дома	Добра	Низька	Так
4	Сильний	Дома	Добра	Висока	Так
6	Слабкий	В гостях	Добра	Висока	Так
8	Сильний	Дома	Добра	Низька	Так
10	Слабкий	Дома	Добра	Висока	Так

CART

Сила суперника:

$Gini(\text{Сильний}) = 1 - (1/3)^2 - (2/3)^2 = 0.4444$

$Gini(\text{Слабкий}) = 1 - (4/4)^2 = 0.0000$

$Gini(\text{Сила суперника}) = 3/7 \times 0.4444 + 4/7 \times 0.0000 = \underline{0.1905}$

Місце матчу:

$Gini(\text{В гостях}) = 1 - (1/2)^2 - (1/2)^2 = 0.5000$

$Gini(\text{Дома}) = 1 - (5/5)^2 = 0.0000$

$Gini(\text{Місце матчу}) = 2/7 \times 0.5000 + 5/7 \times 0.0000 = \underline{0.1429}$ ← Найменший Gini

Підтримка команди:

$Gini(\text{Висока}) = 1 - (1/5)^2 - (4/5)^2 = 0.3200$

$Gini(\text{Низька}) = 1 - (2/2)^2 = 0.0000$

$Gini(\text{Підтримка команди}) = 5/7 \times 0.3200 + 2/7 \times 0.0000 = \underline{0.2286}$

CART

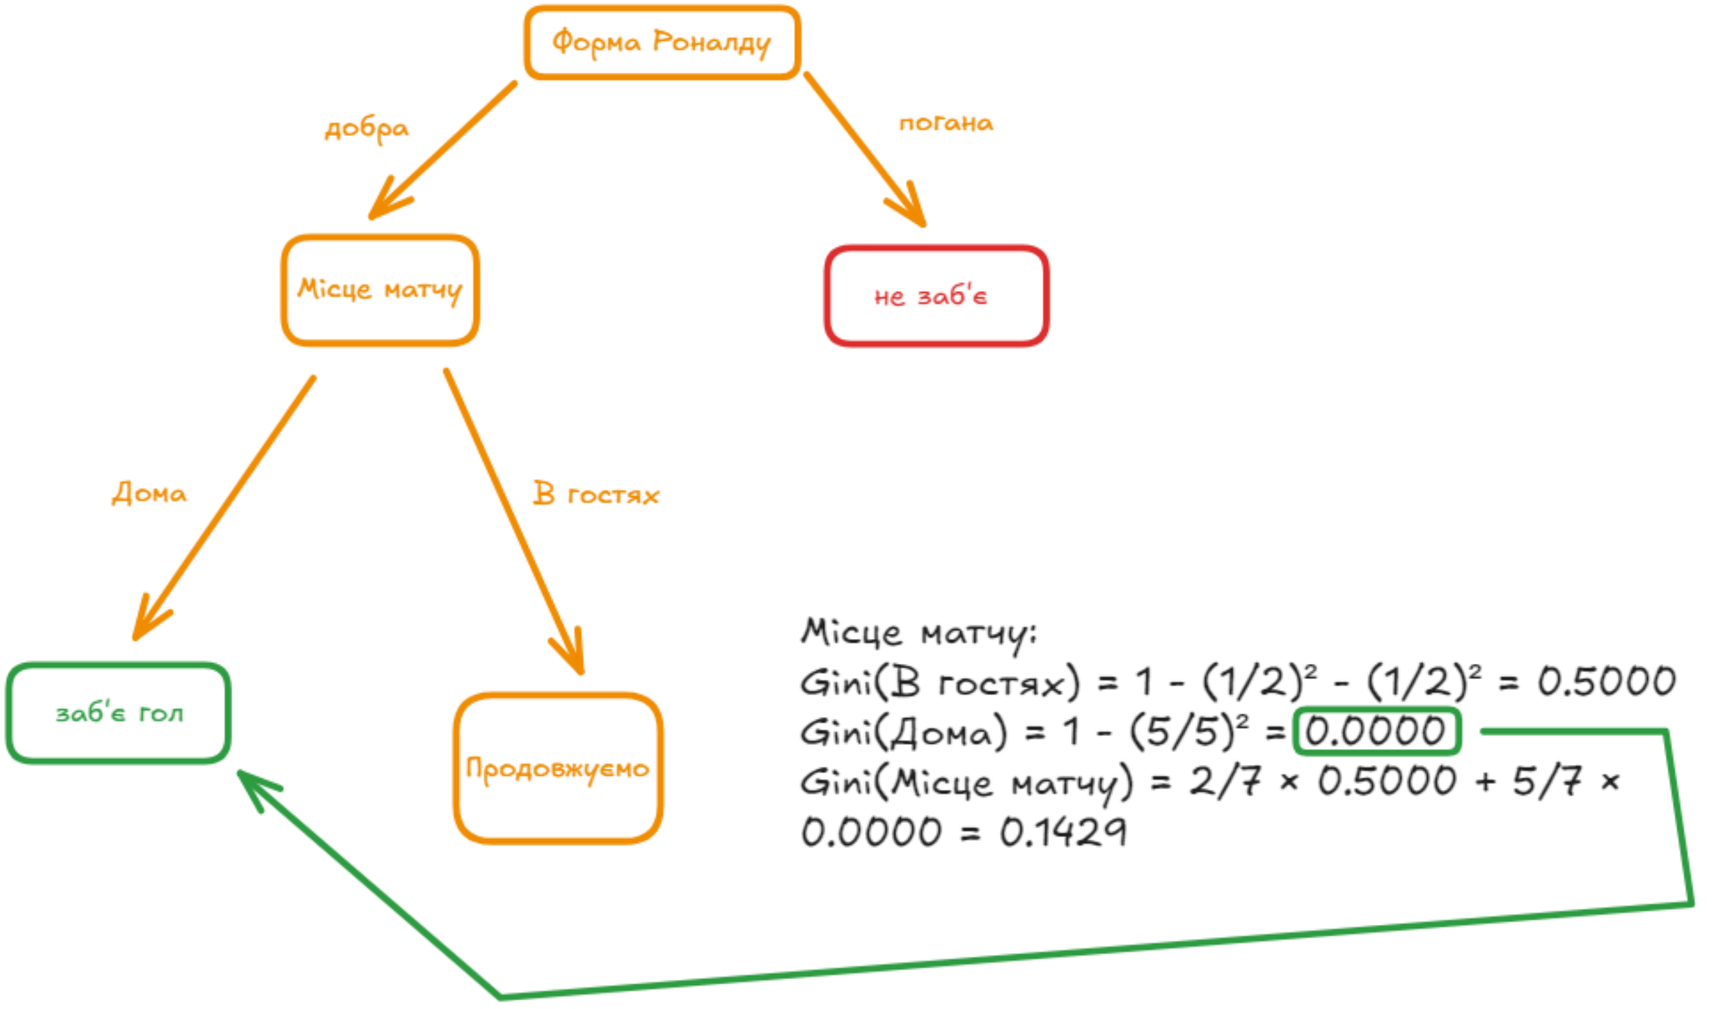
Форма Роналду
добра
погана
Місце матчу
не заб'є
Дома
В гостях
заб'є гол
Продовжуємо
Місце матчу:
Gini(В гостях) = 1 - (1/2)² - (1/2)² = 0.5000
Gini(Дома) = 1 - (5/5)² = 0.0000
Gini(Місце матчу) = 2/7 × 0.5000 + 5/7 × 0.0000 = 0.1429

CART

	Сила суперника	Місце матчу	Форма Роналдо	Підтримка команди	Забив
0	Сильний	В гостях	Добра	Висока	Ні
6	Слабкий	В гостях	Добра	Висока	Так

Сила суперника:

$Gini(\text{Сильний}) = 1 - (1/1)^2 = 0.0000$

$Gini(\text{Слабкий}) = 1 - (1/1)^2 = 0.0000$

$Gini(\text{Сила суперника}) = 1/2 \times 0.0000 + 1/2 \times 0.0000 = 0.0000$

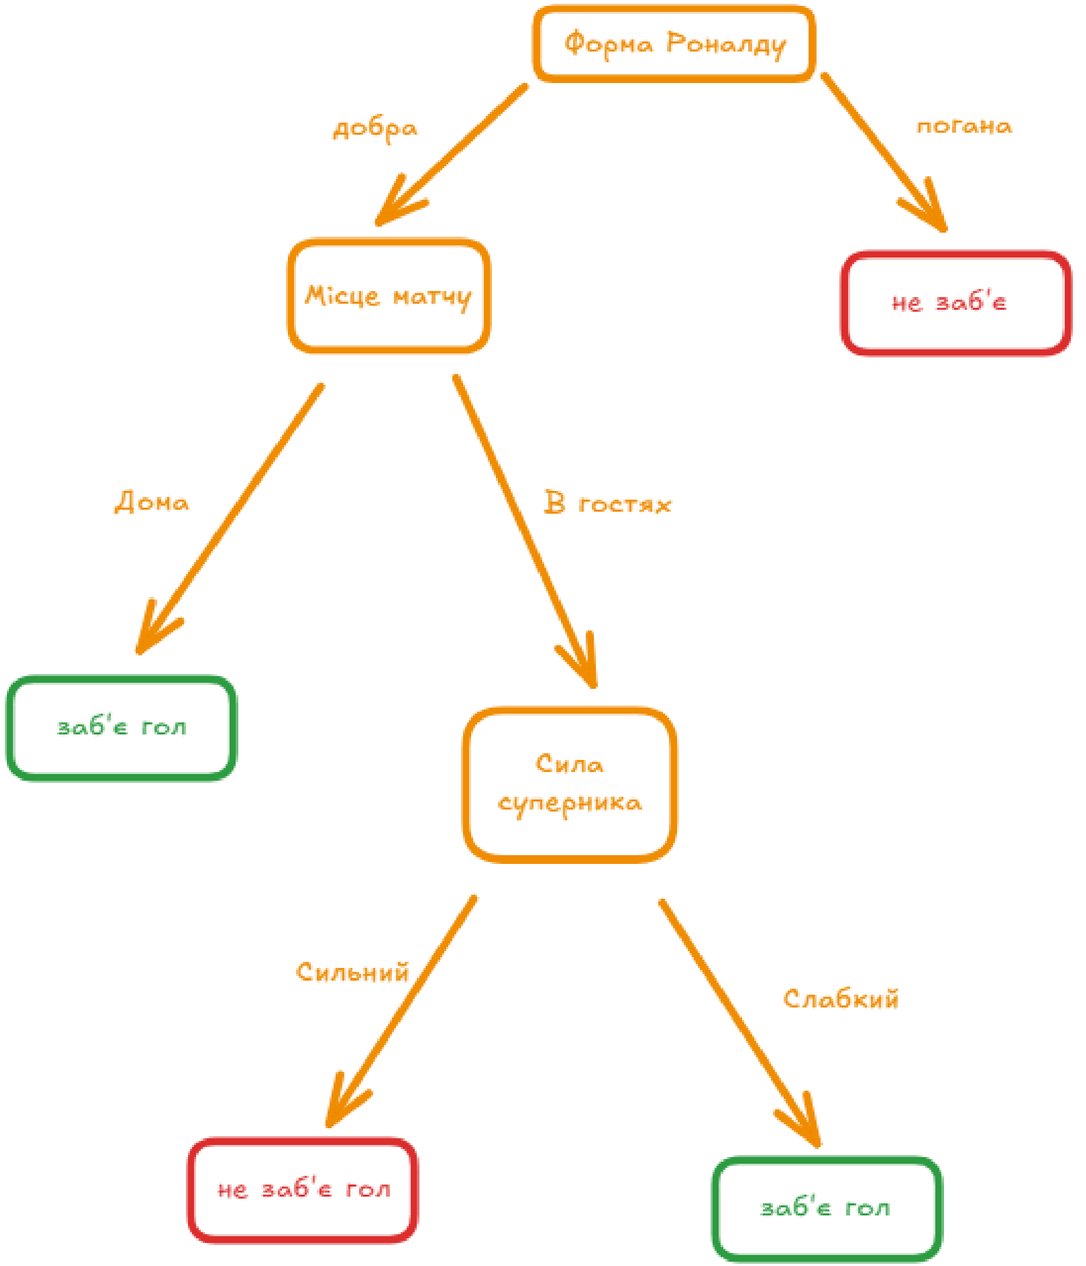
Форма Роналду
добра
погана
Місце матчу
не заб'є
Дома
В гостях
заб'є гол
Сила суперника
Сильний
Слабкий
не заб'є гол
заб'є гол

Тестові дані

Форма Роналдо: Добра
Місце матчу: В гостях
Сила суперника: Слабкий
Підтримка команди: Висока

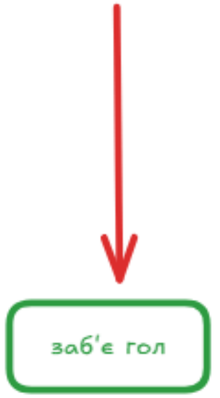

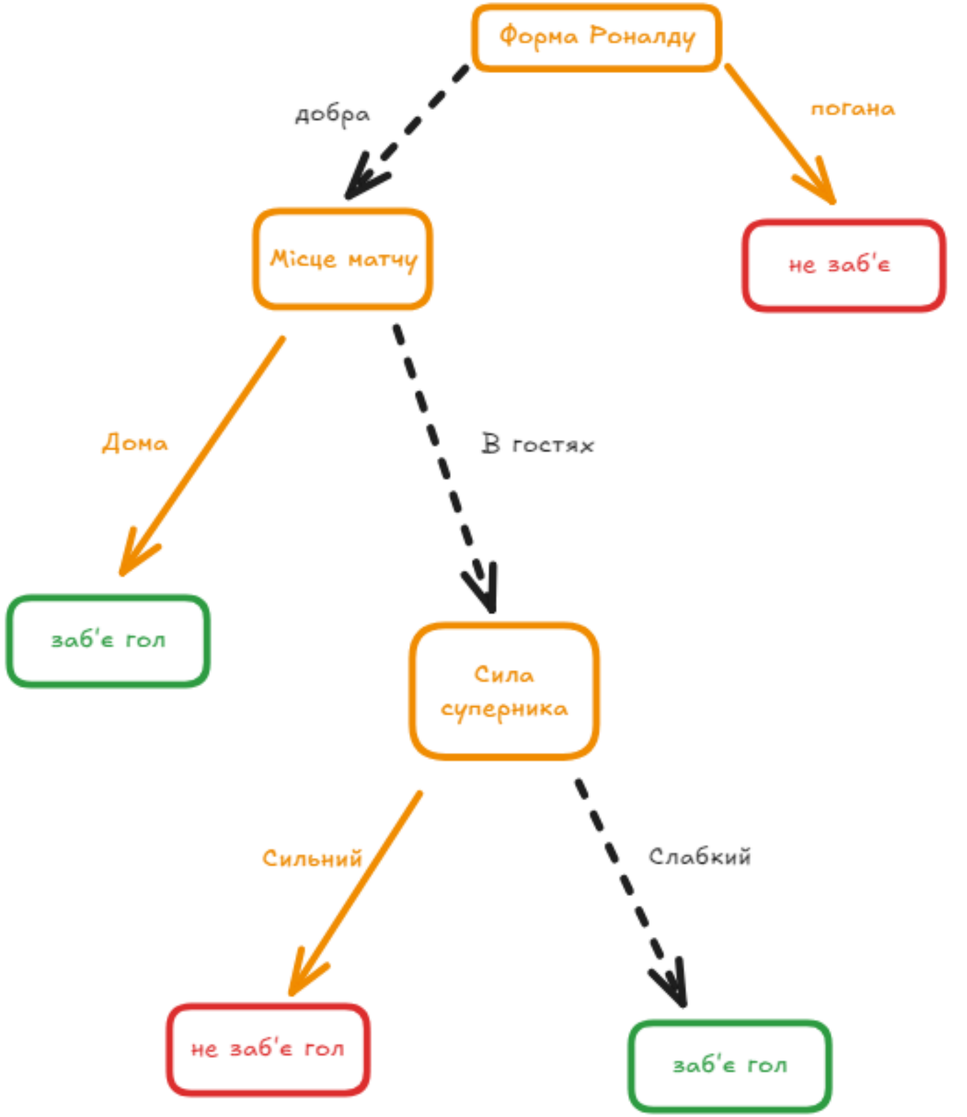

Висновок

У цій роботі я реалізував алгоритм CART для побудови дерева рішень. У процесі реалізації я використав функції для обчислення індексу Gini та автоматичного пошуку найкращих розбиттів даних. Це дозволило побудувати дерево, яке ефективно поділяє вибірку за критерієм чистоти вузлів і може використовуватись для задач класифікації.